



PROYECTO INTEGRADOR

MÓDULO: CIENCIAS DE DATOS Y OPTIMIZACIÓN DE MODELOS

CARRERA: TECNICATURA UNIVERSITARIA EN PRODUCCIÓN AUDIOVISUAL



Proyecto Integrador

Objetivo del Proyecto

El objetivo de este proyecto integrador es proporcionar al estudiantado una experiencia práctica y completa en el campo de análisis de datos y aprendizaje automático. A lo largo de las dos entregas obligatorias, se explorarán diferentes aspectos clave de este campo, desde el análisis exploratorio de datos y la visualización hasta la construcción principalmente de modelos de clasificación.

Integrantes

Este proyecto integrador se llevará a cabo en grupos de 4 personas, donde cada miembro tendrá la oportunidad de colaborar y aportar sus habilidades y conocimientos en el campo análisis de datos y el Aprendizaje Automático.

Formato de entrega

Conjunto de datos seleccionado y notebook que cumpla con las tareas solicitadas. Es decir un archivo con formato .ipynb. Se pretende que la notebook presente el análisis de datos y código comentado sin errores.

Conjunto de datos

Un aspecto destacado de este proyecto es la flexibilidad en la elección del conjunto de datos o dataset. Cada equipo tendrá la libertad de seleccionar el conjunto de datos que desee utilizar, ya sea que lo tengan disponible previamente o que lo descarguen de repositorios públicos relevantes. Esto permitirá que cada grupo trabaje con datos que sean de su interés o estén relacionados con sus áreas de especialización.





Ante un primer acercamiento a los datos, es recomendable aproximarse a ellos a través de la metadata, el diseño de registro o el diccionario de datos.

Sugerencia : recuadro 5 de Hoja de Ruta “Innovar con Ciencia de Datos en el sector público”.

Como recomendación fuentes de datos que pueden utilizar:

- UCI Machine Learning Repository: <https://archive.ics.uci.edu/ml/index.php>
- Kaggle: <https://www.kaggle.com/>
- Datos Argentina: <https://www.datos.gob.ar/>

Condiciones: Conjunto de datos con más de 1000 registros, con variables cuantitativas y/o cualitativas, con la información suficiente para proporcionar una breve descripción de las variables presentes, incluyendo su nombre y tipo, lo que representa, cómo se mide, etc. El conjunto de datos debe poder utilizarse, es decir no tiene restricciones de uso.

Preguntas que pueden guiar la selección de datos: ¿Qué quiero resolver o mejorar con estos datos? (Problema) ¿Cuál sería el objetivo o propósito de análisis? ¿estos datos son los adecuados para el propósito?

Fichas para completar sobre el conjunto de datos seleccionado

Fuente de recolección y origen de los datos	
Nombre del conjunto de datos utilizado.	
¿Qué institución creó el conjunto de datos?	
¿Con qué propósito creó la institución el conjunto de datos empleado?	
¿Qué mecanismos o procedimientos se usaron para recoger los datos (por ejemplo, encuesta de hogares, sensor, software, API)? .	
¿Existe documentación para obtener información sobre cada variable del conjunto de datos?	





Diccionario de datos				
Nombre de variable	Descripción	Tipo de dato	Valores aceptados	¿Acepta valores faltantes? Permite que falte dato. De no permitirlo tener en cuenta esta información para la limpieza de los datos.

Cronograma

Entregas del proyecto integrador	Fecha
Primera entrega parcial	Lunes 11/05
Segunda entrega parcial	Lunes 08/06
Entrega final	Lunes 29/06

Entrega 1

El objetivo de esta primera entrega es que el estudiantado identifique la importancia de la calidad de los datos y adquiera habilidades en el análisis exploratorio de datos ante un objetivo definido.





Para realizar la entrega 1 se sugiere haber completado las Fichas sobre el conjunto de datos seleccionado.

Consigna:

1. Objetivos y alcances:
 - a. Identificar y definir el objetivo general de uso del conjunto de datos.
 - b. Describir las variables presentes en el conjunto de datos.
2. Análisis exploratorio de datos:
 - a. Cargar el archivo asociado al conjunto de datos por medio de la librería Pandas y controlar que se haya realizado correctamente.
 - b. Identificar las variables potencialmente importantes para tu objetivo. Diferenciar entre variables cuantitativas y cualitativas.
 - c. Realizar un resumen descriptivo de las variables, como calcular medidas de tendencia central, dispersión y correlación (análisis univariado).
 - d. Identificar posibles problemas en los datos, como valores atípicos o valores faltantes.
 - e. Plantear preguntas de interés teniendo en cuenta las variables potenciales. Mínimo tres preguntas.
3. Visualización de datos:
 - a. Crear gráficos adecuados como gráfico de barra, histogramas, diagramas de dispersión, diagramas de caja, etc. Usar las librerías Matplotlib o Seaborn.

Cada gráfico será interpretado con el fin de obtener información relevante que permitan dar respuesta a las preguntas planteadas y objetivo general.
 - b. Explorar la relación entre diferentes variables mediante gráficos de dispersión o gráficos de correlación.
4. Problemas con datos:
 - a. Identificar y evaluar la cantidad de datos faltantes en el conjunto de datos.
 - b. Identificar valores atípicos en el conjunto de datos.





5. Conclusión: Plantear la información relevante de este primer análisis y detallar las facilidades y dificultades, en caso de poder identificarlos, de utilizar los datos seleccionados.

Recuerda, esto es un proceso iterativo, aquí inicias la exploración y primer análisis. En la siguiente entrega podrás seguir reforzando estos puntos de ser necesario para avanzar al modelado.

Fecha de Entrega: Ver en plataforma

Entrega 2

En la segunda entrega, el objetivo es que el estudiantado desarrolle habilidades en la construcción y optimización de modelos predictivos.

Se trabajarán los modelos clasificación preferentemente, permitiendo al estudiantado comprender y aplicar estos algoritmos para resolver problemas específicos. También se abordará el aprendizaje no supervisado y la reducción de la dimensión, lo que permitirá explorar y analizar datos sin etiquetas y mejorar la eficiencia del modelado.

Se parte de la entrega 1

Consigna:

- **Objetivos y alcances:** Definir y detallar problema o necesidad a resolver. Determinar si se trata de un problema de clasificación. En base a ellos seguir las actividades correspondientes a los modelos por tipo de problema.
- **Análisis exploratorio de datos:** en base a lo realizado en entrega 1, detallar el análisis univariado y bivariado de las variables potenciales para el objetivo (variable objetivo y las variables predictoras). Aquí se pretende revisar lo realizado teniendo en cuenta el tipo de problema a resolver.
- **Modelado - Aprendizaje supervisado:**

Si es de clasificación





- Seleccionar una variable objetivo y las variables predictoras adecuadas para el modelado de clasificación.
 - Aplicar un modelo de clasificación, como árboles de decisión o regresión logística.
 - Evaluar el rendimiento del modelo utilizando métricas apropiadas.
 - Optimización del modelo: Ajuste de hiperparámetros con GridSearch y RandomSearch.
-
- Modelado - Aprendizaje no supervisado y reducción de la dimensión:
 - Identificar patrones o grupos en los datos utilizando algoritmos de clustering, como K-means.
 - Reducir la dimensionalidad de los datos utilizando técnicas como PCA (Análisis de Componentes Principales)
 - Visualizar los resultados del aprendizaje no supervisado y la reducción de la dimensión para comprender mejor la estructura de los datos.
-
- Conclusión: Plantear la información relevante de estos primeros modelos y detallar las facilidades y dificultades, en caso de poder identificarlos, de utilizar los datos seleccionados y crear los modelos.

Fecha de Entrega: Ver en plataforma

Recuerda, esto es un proceso iterativo, aquí ya avanzaste a trabajar con modelos de aprendizaje automático. En la siguiente entrega podrás seguir reforzando estos puntos de ser necesario.

Entrega Final

La última entrega se enfocará en simular la entrega de un proyecto inicial de Ciencia de Datos. El mismo deberá contemplar las entregas 1 y 2 que mantienen un orden de estudio de los datos. El trabajo final deberá presentar las siguientes secciones:

- Comprensión del problema
- Recolección de datos



- Análisis de datos
- Modelado
- Conclusiones

Formato de entrega: Notebook con las secciones indicadas, y código comentado sin errores.